

MLIR for AI/NPU Compiler - Lecture 01 Worksheet

Goal: MatMul+Bias+ReLU 에 대한 NPU compiler lowering pipeline 초안을 작성한다.

A. Warm-up Questions

MLIR 에서 dialect 가 필요한 이유를 NPU compiler 관점에서 설명하세요.

StableHLO/TOSA 와 Custom NPU Dialect 의 역할 차이를 설명하세요.

Tensor IR 에서 너무 빨리 low-level loop 로 lowering 하면 어떤 최적화 기회를 잃나요?

Bufferization 이후 compiler 가 새로 결정해야 하는 정보는 무엇인가요?

DMA/compute overlap 이 없는 schedule 은 latency 에 어떤 영향을 주나요?

B. Pipeline Table

Step	Input IR	Output IR	Compiler decision	Verification
Import				
Legalize				
Canonicalize				
Fuse				
Tile				
Bufferize				
Schedule				
Emit				

C. NPU Target Constraints

Constraint	Assumption	Compiler response
PE tile	64x64	
K chunk	128	
SRAM	2MB	
DMA	double buffering	
Data type	FP16/FP32-acc or INT8/INT32-acc	
Runtime	descriptor + command buffer	

