

MLIR NPU Compiler - Lecture 03 Worksheet

주제: Region 과 Block 을 읽고 NPU command region pseudo IR 을 설계합니다.

Exercise A. Region/Block Annotation

아래 MLIR snippet 에서 Operation, Region, Block, Block Argument, Terminator 를 표시하세요.

```
func.func @copy(%A: memref<1024xf32>, %B: memref<1024xf32>) {
  %c0 = arith.constant 0 : index
  %c1 = arith.constant 1 : index
  %c1024 = arith.constant 1024 : index
  scf.for %i = %c0 to %c1024 step %c1 {
    %x = memref.load %A[%i] : memref<1024xf32>
    memref.store %x, %B[%i] : memref<1024xf32>
  }
  return
}
```

항목	찾은 위치	설명
Region		
Block argument		
Terminator		
Nested operation		

Exercise B. Block Argument Merge

아래 CFG 에서 ^merge(%x : i32)의 %x 가 어떤 값에서 올 수 있는지 설명하세요.

```
cf.cond_br %cond, ^then, ^else
^then:
  %a = arith.constant 1 : i32
  cf.br ^merge(%a : i32)
^else:
  %b = arith.constant 2 : i32
  cf.br ^merge(%b : i32)
^merge(%x : i32):
  scf.yield %x : i32
```

답안:

Exercise C. NPU Command Region Design

MatMul tile 하나에 대해 pseudo npu.command_buffer region 을 작성하세요. 최소 요구 사항: DMA A, DMA B, await/barrier, matmul, requant/relu, DMA store, yield.

```
"npu.command_buffer"() ({
  ^entry(%A: !npu.tensor_desc, %B: !npu.tensor_desc, %C: !npu.tensor_desc):
    // TODO: DMA A tile DRAM -> SRAM
    // TODO: DMA B tile DRAM -> SRAM
    // TODO: await tokens
    // TODO: matmul
    // TODO: requant/relu
    // TODO: DMA output SRAM -> DRAM
    // TODO: terminator
```

```
}): () -> ()
```

Exercise D. Verifier Checklist

Check	Pass/Fail	Reason
Every block has a terminator		
Block argument types match branch operands		
DMA tokens are awaited before compute		
SRAM/ACC views do not escape illegally		
Compile-time metadata is encoded as attributes		
Command order is deterministic		

Instructor Notes

- 학생이 region 자체가 semantics 를 정한다고 오해하면 parent operation 이 semantics 를 정한다는 점을 다시 강조하세요.
- Block argument 는 phi node 를 쓰지 않는 MLIR 의 핵심 표현입니다.
- NPU pseudo IR 에서는 token, memory space, terminator 세 가지가 빠지기 쉽습니다.