

MLIR / NPU Compiler Course - Lecture 05

Worksheet

Dialect System 설계 실습

실습 목표

- 주어진 IR/operator 를 적절한 dialect layer 로 분류한다.
- custom NPU operation 의 operand/result/attribute/type/verifier 를 설계한다.
- frontend -> graph -> kernel -> runtime lowering boundary 를 정의한다.
- ODS pseudo skeleton 과 FileCheck 테스트 계획을 작성한다.

Exercise A. Dialect Layer Classification

아래 operator 또는 metadata 가 어느 dialect layer 에 속하는지 표시하고 이유를 적으세요.

항목	Frontend	Graph	Kernel	Runtime	선택 이유
stablehlo.dot_general					
layout propagation hint					
npu_kernel.dma_load					
tensor descriptor stride field					
per-channel quant scale					
barrier token dependency					
command buffer launch					
fusion group for MatMul+Bias+ReLU					

Exercise B. npu_kernel.matmul Operation Schema

아래 표를 채워 npu_kernel.matmul pseudo op 를 설계하세요.

항목	설계 내용
Operation name	
Operands	
Results	
Attributes	
Types	
Traits/Interfaces	
Verifier rules	
Assembly format	
Lowering target	

Exercise C. Attribute vs Operand vs Type

다음 정보를 Attribute, Operand, Type 중 어디에 돌지 결정하고 근거를 작성하세요.

정보	Attribute	Operand	Type	근거
tile_shape [16, 16, 32]				
runtime tensor pointer				
SRAM memory space				
per-core command buffer handle				
dynamic sequence length				
accumulator precision i32				
DMA burst length				

Exercise D. Dialect Boundary Design

MatMul + Bias + ReLU lowering pipeline 을 4 개 dialect layer 로 나누고 각 boundary 에서 수행할 pass 와 test 를 적으세요.

Boundary	Input dialect	Output dialect	주요 pass	Legality check	FileCheck 테스트 이름
Import -> Graph					
Graph -> Kernel					
Kernel -> Runtime					
Runtime -> Binary/Command					

Exercise E. ODS Pseudo Skeleton

아래 skeleton 의 빈칸을 채우세요.

```
def NPUKernel_MatMulOp : NPUKernel_Op<"matmul", [/* traits */]> {
  let summary = "_____";
  let arguments = (ins _____);
  let results    = (outs _____);
  let assemblyFormat = "_____";
  let hasVerifier = 1;
}

// verifier 에서 반드시 잡을 rule 3 개
// 1.
// 2.
// 3.
```

Mini Quiz

- 1. Dialect 와 operation namespace 의 관계를 한 문장으로 설명하세요.
- 2. npu_graph.matmul 과 npu_kernel.matmul 을 분리해야 하는 이유를 2 가지 쓰세요.
- 3. compile-time metadata 가 대부분인 tile_shape 는 operand 보다 attribute 가 자연스러운 이유를 설명하세요.
- 4. pass 가 새 dialect entity 를 생성할 때 getDependentDialects 가 중요한 이유를 쓰세요.
- 5. verifier 에서 SRAM capacity check 를 하지 않으면 어떤 문제가 생길 수 있나요?

제출물

- 1-page dialect layering diagram 또는 표
- npu_kernel.matmul ODS pseudo definition
- Dialect boundary 별 pass/test matrix
- Verifier rule checklist 10 개 이상