

MLIR NPU Compiler - Lecture 06 Worksheet

StableHLO/TOSA input IR, LayerNorm/GELU decomposition

Part A. StableHLO vs TOSA 비교

아래 표를 완성하세요.

항목	StableHLO	TOSA	NPU compiler decision
Primary role			
대표 op 5 개			
Composite pattern 보존			
Quantization path			
Dynamic shape 처리			

Part B. LayerNorm decomposition

Input: $x[B,S,K]$, $\gamma[K]$, $\beta[K]$. $K=768$ 이라고 가정합니다. 각 단계의 shape 와 NPU kernel mapping 을 적으세요.

Step	Expression	Output shape	NPU mapping/check
1	$\text{mean} = \text{reduce_sum}(x, \text{axis}=K) / K$		
2	$\text{center} = x - \text{broadcast}(\text{mean})$		
3	$\text{var} = \text{reduce_sum}(\text{center} * \text{center}, \text{axis}=K) / K$		
4	$\text{inv} = \text{rsqrt}(\text{var} + \text{eps})$		
5	$\text{out} = \text{center} * \text{inv} * \gamma + \beta$		

Part C. GELU lowering policy

아래 조건에서 어떤 GELU lowering 을 선택할지 결정하세요.

Scenario	Chosen lowering	Reason	Regression test
FP16 transformer MLP, accuracy sensitive			
INT8 activation with fixed calibration range			
NPU has tanh but no erf			
MatMul epilogue bandwidth bottleneck			

Part D. NPU legal op audit

Imported op/pattern	Target support	Action	Verifier rule	Fallback
---------------------	----------------	--------	---------------	----------

stablehlo.dot_general				
stablehlo.erf				
tosa.reduce_sum axis=-1				
tosa.rsqrt				
dynamic reshape/gather				

Part E. Reflection

- StableHLO/TOSA 에서 너무 일찍 lower 하면 잃는 정보는 무엇인가?
- 반대로 너무 늦게 lower 하면 NPU compiler 에서 어떤 문제가 생기는가?
- 6 강 내용을 기반으로 20 강 Capstone 에서 사용할 input IR boundary 를 정의해보세요.