

MLIR NPU Compiler - Lecture 08 Worksheet

SCF/Affine Loop Practice

실습 A. scf.for Anatomy Annotation

아래 코드에서 lower bound, upper bound, step, induction variable, body operation, terminator 를 표시하세요.

```
scf.for %i = %c0 to %c128 step %c1 {  
  %a = memref.load %A[%i] : memref<128xf32>  
  memref.store %a, %B[%i] : memref<128xf32>  
}
```

lower bound: _____

upper bound: _____

step: _____

induction variable: _____

body operations: _____

NPU compiler 관점의 의미: _____

실습 B. M/N/K Tile Loop 작성

Shape `A[128,256] x B[256,128]` -> `C[128,128]`, tile `TM=32`, `TN=64`, `TK=64`에 대해 loop trip count 와 loop nest 를 작성하세요.

Loop	Range	Step	Trip count
m0			
n0			
k0			

Pseudo MLIR loop nest:

실습 C. SRAM Footprint 계산

int8 input, int32 accumulator, double-buffered A/B 라고 가정하세요.

항목	계산식	결과
A tile	$TM \cdot TK \cdot 1$	
B tile	$TK \cdot TN \cdot 1$	
Accumulator	$TM \cdot TN \cdot 4$	
Total	$2 \cdot (A+B) + Acc$	

SRAM budget 이 24KB 이고 alignment/tag overhead 가 2KB 라면 이 tile 은 가능한가? 이유를 쓰세요.

실습 D. DMA Schedule Table

Double buffering 을 사용한다고 가정하고, k0 tile 0~3 에 대한 DMA/compute/wait 순서를 작성하세요.

Step	Buffer	DMA action	Compute action	Wait/Barrier
1				
2				
3				
4				
5				
6				
7				
8				

실습 E. SCF vs Affine Decision

다음 compiler task 를 SCF/Affine 중 어디에 두는 것이 좋은지 선택하고 이유를 쓰세요.

Task	SCF/Affine	Reason
static 2D tiled matmul loop		
runtime shape branch		
affine memory access analysis		
DMA command ordering		
edge tile mask decision		

Answer Sketch

B: m0 trip count 4, n0 trip count 2, k0 trip count 4. C: A=2KB, B=4KB, Acc=8KB, total=20KB + overhead; 24KB budget with 2KB overhead leaves 22KB, so feasible but tight. D: preload buffer0, compute buffer0 while loading buffer1, alternate, wait just before consume.