

MLIR NPU Lecture 10 Worksheet

Rewrite Pattern - MatMul + Add + ReLU Fusion

이 워크시트의 목표는 pattern matching checklist 와 fused op replacement contract 를 직접 작성하는 것입니다.

A. Operation Chain Annotation

아래 IR 흐름에서 root op, producer op, bias operand, replacement op 를 표시하세요.

```
%mm      = linalg.matmul ins(%A, %B) outs(%init)
%add_bias = linalg.generic ins(%mm, %bias) outs(%empty1) { arith.addf ... }
%relu     = linalg.generic ins(%add_bias) outs(%empty2) { arith.maxnumf ... }
// replacement: "npu_graph.matmul_epilogue"(%A, %B, %bias) {activation = "relu"}
```

항목	학생 작성
Root operation	
MatMul producer	
Bias operand	
Replacement op	
기존 op 중 erase 대상	

B. Match Predicate 설계

순서	Predicate	필요한 이유	notifyMatchFailure 메시지
1			
2			
3			
4			
5			
6			
7			
8			

C. NPU Fusion Contract

분류	확인할 조건	Pass/Fail 기준
Semantic		
Use-def		
Shape/Broadcast		
DType/Quant		
Layout		
SRAM/Runtime		

D. Pattern Benefit 결정

다음 pattern 들의 benefit 우선순위를 정하고 이유를 쓰세요.

Pattern	추천 benefit	이유
MatMul + Bias + ReLU -> FusedEpilogue		
MatMul + Bias -> FusedBias		
ReLU canonicalization		
Add identity elimination		

E. FileCheck Test 작성

Positive test 와 negative test 에 들어갈 CHECK line 을 작성하세요.

```
// Positive
// CHECK-LABEL:
// CHECK:
// CHECK-SAME:
// CHECK-NOT:

// Negative: shared MatMul result must not fuse
// CHECK-LABEL:
// CHECK-NOT:
```

F. 토론 질문

- shared MatMul result 를 clone 하고 fusion 하는 전략은 언제 허용될 수 있나요?
- INT8 output 에서 ReLU 를 fused epilogue 로 넣을 때 requant 전/후 activation 위치는 어떻게 결정해야 하나요?
- layout transform 을 fusion pattern 안에서 수행해야 할까요, 아니면 별도 layout propagation pass 에서 수행해야 할까요?