

Lecture 16 Worksheet

Quantization for NPU Compiler

실습 A - qparams 계산

입력 activation 의 calibration range 가 $\min=-1.6$, $\max=1.4$ 이고 signed i8 symmetric/asymmetric 정책 중 하나를 선택할 수 있다고 가정합니다. scale, zero_point, clamp range 를 계산하고 선택 이유를 설명하세요.

정책	scale	zero_point	설명
----	-------	------------	----

실습 B - MLIR Quant Type Annotation

아래 pseudo IR 에서 expressed type, stored type, scale, zero_point, per-channel axis 를 표시하세요.

```
%qa = quant.qcast %a : tensor<1x128xf32>
      to tensor<1x128x!quant.uniform<i8:f32, 0.03125:-3>>
%qw = quant.qcast %w : tensor<128x64xf32>
      to tensor<128x64x!quant.uniform<i8:f32:1,
      {0.015, 0.017, 0.022, ...}>>
```

실습 C - Accumulator Width 계산

INT8 MatMul 에서 $K=4096$, activation/weight 는 symmetric int8 $[-127, 127]$ 입니다. worst-case accumulator bound 와 필요한 bit width 를 계산하세요. bias margin 은 2^{24} 로 가정합니다.

항목	값
max_abs_a	
max_abs_w	
$K * \text{product}$	
bias_margin	
required_bits	

실습 D - Requant Multiplier/Shift

sa=0.03125, sw=0.015625, sy=0.0078125 라면 $r = sa * sw / sy$ 를 계산하고, $r \approx M/2^S$ 형태로 근사하세요. M 은 31-bit signed positive 범위에 들어가야 합니다.

실습 E - INT4 Packing Contract

s4 weight-only MatMul 을 target NPU 에 내린다고 가정하고 아래 표를 완성하세요.

항목	정책	검증 방법
signedness		
nibble order		
group_size		
K alignment		
scale layout		
DMA padding		
fallback		

실습 F - Negative Test 설계

- per-channel scale 수와 output channel 수가 맞지 않는 case
- K 가 int4 group_size 로 나누어지지 않는 case
- requant shift 가 target 최대값을 넘는 case
- bias scale 이 $sa * sw$ 와 다르게 들어온 case
- i32 accumulator overflow 가능성이 있는 case

제출물 체크리스트

- quantization policy YAML
- accumulator width 계산표
- MLIR pseudo lowering
- FileCheck positive/negative test
- INT4 runtime descriptor draft