

Lecture 17 Worksheet - Fusion and Layout Propagation

Exercise A - Fusion 후보 표시

아래 MLP 흐름에서 fusion group 을 표시하고, 각 group 의 root op 를 정하세요.

X → MatMul1 → Bias1 → GELU → MatMul2 → Bias2 → Y

Group 1: _____

Group 2: _____

Group 3: _____

Exercise B - Legality Matrix

Candidate	Shape	DType/Quant	Layout	Decision
MatMul+Bias				
MatMul+Bias+GELU				
SwiGLU elementwise				
Layout propagation				
Weight prepack				

Exercise C - Layout Propagation

다음 value 들의 layout 을 채우고, materialization 이 필요한 지점을 명시하세요.

Value	Producer	Preferred layout	Materialize? reason
%h0	MatMul1		
%h1	Bias1		
%h2	GELU		
%y0	MatMul2		
%y	Bias2		

Exercise D - Traffic/SRAM 계산

H=4096, expansion=4, token tile=128, fp16 기준으로 GEMM1 epilogue fusion 의 intermediate write saving 을 계산하세요.

expanded activation bytes: _____

unfused writes: _____

fused writes: _____

saved writes: _____

SRAM footprint with double buffer:

Exercise E - FileCheck

아래 항목을 포함하는 FileCheck 를 작성하세요.

- npu_graph.matmul_epilogue 존재
- epilogue attribute 확인
- out_layout attribute 확인
- unfused bias/gelu 부재
- layout_materialize count 제한